

Sistema De Estacionamiento Autónomo (S.E.A.)

Luis Angel Renteria Jimenez, Jimena García Orozco, Gael Antonio Torres Aceves

Centro Universitario de Ciencias Exactas e Ingenierías (CUCEI, UDG)

luis.renteria5160@alumnos.udg.mx

jimena.garcia5526@alumnos.udg.mx

gael.torres5301@alumnos.udg.mx

josed.hernandezb@academicos.udg.mx

Abstract— Este trabajo presenta el desarrollo de un Sistema de Estacionamiento Autónomo (S.E.A.) para vehículos con dirección tipo Ackermann. El sistema integra tres módulos principales: un controlador adaptable de velocidad angular de motores DC basado en análisis de Lyapunov, una Red Neuronal Multicapa (MLP) para detección de espacios de estacionamiento mediante sensores ultrasónicos, y un sistema electrónico basado en el microcontrolador ESP32 con puente H y regulación de voltaje. Las simulaciones en MATLAB/Simulink y CoppeliaSim validaron el controlador adaptable, mientras que la MLP alcanzó un accuracy del 95% en entrenamiento y 93.5% en prueba. La planificación de trayectorias mediante Splines permite ejecutar la maniobra de estacionamiento en reversa de manera autónoma y precisa.

Palabras clave— Estacionamiento autónomo, control adaptable, Lyapunov, red neuronal MLP, sensores ultrasónicos, Ackermann, ESP32, Splines.

I. INTRODUCCIÓN

La industria automotriz evoluciona a un ritmo acelerado, impulsando el desarrollo de sistemas de conducción autónoma que buscan resolver problemas de movilidad urbana, seguridad vial y eficiencia en el uso del espacio. El estacionamiento en reversa representa uno de los desafíos más frecuentes para los conductores y constituye una de las principales causas de accidentes menores en zonas urbanas [1].

Específicamente, la maniobra de estacionamiento en reversa implica restricciones de movimiento no holonómicas propias de los vehículos con dirección tipo Ackermann, lo que dificulta la planificación y ejecución precisa de trayectorias. Sistemas de asistencia actuales aún presentan limitaciones en entornos no estructurados o cuando se requiere maniobrar en espacios reducidos [2].

El presente proyecto propone un sistema integrado capaz de: detectar automáticamente espacios de estacionamiento disponibles mediante sensores ultrasónicos y una red neuronal, planificar una trayectoria de estacionamiento mediante Splines cúbicos, y ejecutar la maniobra mediante un controlador adaptable de velocidad basado en análisis de Lyapunov. La validación se realizó tanto en simulación (MATLAB/Simulink y CoppeliaSim) como con un prototipo físico.

II. TRABAJOS RELACIONADOS

Wang y Liu [1] presentaron una revisión exhaustiva de estrategias de estacionamiento autónomo, identificando los

principales enfoques: basados en geometría, en optimización y basados en aprendizaje automático, destacando los retos en escenarios dinámicos y la necesidad de integración sensorial robusta.

LaValle [2] abordó la planificación de movimiento para vehículos no holonómicos, estableciendo las bases teóricas para sistemas con restricciones cinemáticas como las presentes en vehículos Ackermann, fundamentales para el diseño del planificador de trayectorias de este proyecto.

Gupta y Divekar [3] propusieron un sistema de estacionamiento paralelo autónomo para vehículos con dirección Ackermann de cuatro ruedas, demostrando la viabilidad de controladores geométricos combinados con sensado ultrasónico, inspirando directamente la arquitectura sensorial del S.E.A.

Li et al. [4] desarrollaron un método de planificación de trayectorias de estacionamiento basado en optimización dinámica no lineal con arranque en caliente, aportando referentes sobre la precisión requerida en la generación de trayectorias para maniobras de estacionamiento automático.

III. DESCRIPCIÓN DEL DESARROLLO DEL PROYECTO MODULAR

A. Módulo de Sistemas de Control — Controlador Adaptable de Motor DC

El módulo de control se enfoca en la regulación precisa de la velocidad angular de los motores DC que accionan el vehículo, cuya medición se realiza mediante encoders incrementales acoplados a cada eje. El modelo dinámico de un motor DC puede expresarse como:

$$\dot{x}_1 = \theta V - \alpha x_1$$

donde $x_1 = \omega$ es la velocidad angular, $\theta = \text{km}/(\text{RJ})$ agrupa parámetros eléctricos y mecánicos, y $\alpha = B/J$ representa la fricción viscosa. Dado que θ y α son parámetros inciertos o variables, se diseñó un controlador adaptable capaz de estimarlos en línea.

Definiendo el error de velocidad $e_1 = x_1 - \omega d$, donde ωd es la velocidad angular deseada, la ley de control se establece como:

$$V = \frac{\hat{\alpha}\omega - ke_1}{\theta}$$

donde $\hat{\alpha}$ es el estimado adaptativo del parámetro. Para garantizar la estabilidad del sistema se propone la función candidata de Lyapunov:

$$E = \frac{1}{2}e_1^2 + \frac{1}{2y}\tilde{\alpha}^2$$

Calculando su derivada temporal y agrupando términos, se obtiene la condición:

$$\dot{E} = -ke_1^2 + \tilde{\alpha}(\omega e_1 + \frac{1}{y}\dot{\tilde{\alpha}})$$

Proponiendo la ley de adaptación $\dot{\tilde{\alpha}} = -\gamma\omega e_1$, la derivada de Lyapunov se reduce a $\dot{E} = -ke_1^2$, que es semidefinida negativa, garantizando estabilidad en el sentido de Lyapunov. Aplicando el principio de invarianza de LaSalle se demuestra que el sistema es asintóticamente estable: $e_1 \rightarrow 0$ y $\tilde{\alpha} \rightarrow 0$ cuando $t \rightarrow \infty$, siempre que $\omega \neq 0$.

El controlador fue implementado y validado en MATLAB/Simulink, donde se observó convergencia asintótica del error de velocidad y de los parámetros estimados hacia sus valores reales. Las gráficas de simulación confirman la convergencia de los parámetros $\hat{\alpha}$ del motor, así como la convergencia de las velocidades angulares ωR y ωL de ambas ruedas.

B. Módulo de Sistemas Inteligentes — Red Neuronal MLP para Detección de Espacios

El módulo de sistemas inteligentes implementa una Red Neuronal Multicapa (MLP) para clasificar, a partir de lecturas de sensores ultrasónicos, si existe un espacio de estacionamiento disponible o no. El sistema utiliza 4 sensores ultrasónicos HC-SR04 posicionados a los lados del vehículo (2 sensores por lado), cada uno generando múltiples mediciones conforme el carro avanza junto al espacio potencial de estacionamiento.

Para reducir la dimensionalidad y el ruido, se calcula el promedio de 8 mediciones consecutivas por sensor, obteniendo así 16 valores representativos como vector de entrada a la red. Esto reduce la entrada de 256 lecturas brutas a únicamente 16 características por muestra, manteniendo la información relevante sobre la geometría del espacio detectado.

La arquitectura de la MLP diseñada es:

- Capa de entrada: 32 neuronas (lecturas promediadas de los sensores)
- Primera capa oculta: 32 neuronas con función de activación ReLU
- Segunda capa oculta: 16 neuronas con función de activación ReLU
- Capa de salida: 1 neurona (clasificación binaria: espacio disponible / no disponible)

El modelo fue implementado en Python utilizando la biblioteca scikit-learn (MLPClassifier), con las siguientes características de entrenamiento: algoritmo de optimización Adam, función de activación ReLU en capas ocultas, tamaño de lote de 10, máximo de 500 épocas, regularización L2 con $\alpha = 0.005$, y parada temprana (early stopping) con fracción de validación del 10%.

El conjunto de datos de entrenamiento contiene 111 muestras en total, divididas en 80 para entrenamiento y 31 para prueba (test_size=31), con random_state=42 para reproducibilidad. El preprocesamiento incluye normalización mediante StandardScaler dentro de un Pipeline de scikit-learn.

Los resultados del clasificador muestran un accuracy de 0.95 en entrenamiento y 0.9354 en prueba, evidenciando buena generalización sin sobreajuste significativo. La Tabla I resume las métricas por clase, y la Tabla II presenta la matriz de confusión obtenida sobre el conjunto completo de 111 muestras.

TABLA I Métricas De Desempeño Del Clasificador MLP

Clase	Precisión	Recall	F1-Score	Soporte
0	0.93	0.96	0.95	57
1	0.96	0.93	0.94	54
Promedio	0.95	0.95	0.95	111

TABLA II Matriz De Confusión — Conjunto Completo (111 Muestras)

	Pred. 0	Pred. 1
Real 0	55	2
Real 1	4	50

La matriz de confusión muestra 55 verdaderos negativos, 50 verdaderos positivos, 2 falsos positivos y 4 falsos negativos, lo que resulta en un F1-score de 0.95 para la clase 0 y 0.94 para la clase 1. El modelo entrenado se exportó como archivo .pkl mediante la librería joblib para su posterior integración en el sistema embebido (NVIDIA Jetson).

C. Módulo de Sistemas Electrónicos — Hardware e Implementación Embebida

El módulo electrónico integra todos los componentes de hardware del S.E.A., asegurando la comunicación, el acondicionamiento de señales y la distribución de energía de manera compacta y confiable mediante una PCB personalizada (Fig.1).




Fig.1 Diseño de PCB personalizada

El microcontrolador principal ESP32 gestiona la lectura de los encoders incrementales para la retroalimentación de velocidad, el control de los sensores ultrasónicos HC-SR04, y la comunicación de alto nivel con la unidad de cómputo.

Los motores DC de 12V son accionados mediante un puente H, que permite el control bidireccional de velocidad y dirección. Para la distribución de energía, se implementó un convertidor reductor (step-down) que convierte la tensión de la batería (12V) a 5V para alimentar el ESP32 y los circuitos lógicos.

Un aspecto crítico del diseño electrónico fue la implementación de un filtro de desacoplamiento en la salida del regulador step-down, compuesto por un capacitor cerámico de 0.01 μF (de decoupling de alta frecuencia, serie 410 o 401) y un capacitor electrolítico de 470 μF a 25V. Esta combinación de capacitores filtra tanto el ruido de alta frecuencia generado por la conmutación del step-down como las caídas de voltaje transitorias producidas por los picos de corriente de los motores y demás cargas inductivas, garantizando una alimentación estable para la lógica digital.

La PCB personalizada fue diseñada para integrar de manera compacta: el ESP32, el módulo puente H, el regulador step-down con su filtro, los conectores para los sensores ultrasónicos HC-SR04, los conectores para encoders, y los puntos de prueba para depuración. El diseño prioriza la separación entre tierras analógica y digital, así como el enrutamiento diferencial de las señales de encoder para minimizar el acople de ruido.

D. Planificación de Trayectorias y Controlador de Seguimiento

La maniobra de estacionamiento se divide en dos fases principales, ambas implementadas en MATLAB y simuladas en CoppeliaSim.

En la primera fase (alineación inicial), el vehículo navega desde su posición actual hasta el punto de inicio de la maniobra de estacionamiento utilizando un controlador de seguimiento de punto con ganancias kv y kw. La posición objetivo se determina a partir de las mediciones de los sensores ultrasónicos y los parámetros geométricos del vehículo (radio de rueda R, distancia entre ejes D, semiancho L).

En la segunda fase (maniobra de reversa), se genera una trayectoria de referencia mediante Splines lineales interpolados sobre un conjunto de puntos de paso (waypoints) almacenados en el archivo path.mat. El controlador sigue esta trayectoria en reversa, con el ángulo de dirección α acotado a $\pm 45^\circ$ para respetar las restricciones mecánicas del vehículo:

$$\alpha = \arctan\left(\frac{\omega D}{v}\right), \quad \alpha \in [-45^\circ, 45^\circ]$$

La odometría se actualiza en cada paso de tiempo $dt = 0.05$ s, integrando el modelo cinemático de Ackermann. El controlador fue validado exitosamente en simulaciones de CoppeliaSim, demostrando que el vehículo sigue la trayectoria planificada y alcanza la posición de estacionamiento con error mínimo.

IV. RESULTADOS OBTENIDOS DEL PROYECTO

Las simulaciones en MATLAB/Simulink confirmaron, bajo el modelo dinámico del motor DC, la convergencia asintótica prevista por el análisis de Lyapunov, con $e_1 \rightarrow 0$ y los parámetros estimados convergiendo a sus valores reales.

La implementación del controlador adaptable en el ESP32, operando en tiempo real sobre los motores DC con retroalimentación directa de encoders incrementales, corroboró experimentalmente los resultados de simulación. Los datos capturados del hardware real muestran convergencia asintótica del error de seguimiento $e_1 \rightarrow 0$ en ambas ruedas (Fig. 2), así como la convergencia de los parámetros estimados $\hat{\alpha}$ hacia sus valores reales durante la operación en lazo cerrado (Fig. 3). A diferencia de la simulación, la implementación física estuvo sujeta a perturbaciones reales como fricción estática, ruido en las lecturas del encoder y variaciones de carga, por lo que la convergencia observada valida no solo el diseño teórico sino también la robustez práctica del controlador adaptable ante condiciones no modeladas.

La Red Neuronal MLP fue entrenada con 80 muestras y evaluada con 31 casos de prueba, obteniendo un accuracy de 0.95 en entrenamiento y 0.9354 en prueba. La reducción de 256 a 16 características por muestra (promediando 8 mediciones por sensor) fue efectiva para mantener la información relevante del espacio mientras se simplificaba el modelo. El modelo final se desplegó en la Nvidia Jetson Nano para inferencia en tiempo real durante el recorrido de detección.




Fig.2 Graficas de convergencia en ambas ruedas




Fig.3 Graficas de convergencia de parámetros estimados de ambas ruedas

Las simulaciones en CoppeliaSim demostraron que el vehículo es capaz de ejecutar la maniobra completa: detectar el espacio, posicionarse en el punto de inicio y completar el estacionamiento en reversa siguiendo la trayectoria de Splines. Los perfiles de velocidad v y velocidad angular w mostraron comportamiento suave, dentro de las restricciones cinemáticas del vehículo.

En la implementación física del robot móvil tipo coche, la MLP demostró un desempeño sólido durante la detección de espacios en tiempo real, clasificando correctamente la disponibilidad del lugar de estacionamiento conforme el vehículo avanzaba junto a él. Una vez detectado el espacio, el coche ejecutó de manera correcta la maniobra de estacionado en reversa, gobernado por el control adaptable implementado en el ESP32. El espacio de estacionamiento utilizado en las pruebas físicas fue de $90 \text{ cm} \times 35 \text{ cm}$, lo que representa aproximadamente el 150% del

tamaño del robot móvil, un margen ajustado que puso a prueba la precisión del sistema de planificación de trayectorias y del controlador de seguimiento.

La PCB personalizada fue fabricada exitosamente, logrando la integración compacta de todos los módulos electrónicos. El filtro de desacoplamiento implementado (capacitor cerámico 0.01 μF + electrolítico 470 $\mu\text{F}/25\text{V}$) demostró ser efectivo para estabilizar la alimentación del sistema ante las demandas transitorias de corriente de los motores de 12V.

El seguimiento de la trayectoria planificada mediante Splines fue evaluado registrando la posición actual del vehículo contra la posición deseada a lo largo del tiempo. La Fig. 4 muestra las curvas de posición actual (x_a , y_a) y deseada (x_d , y_d): se observa que el vehículo sigue de manera precisa la referencia en ambos ejes, con un error de seguimiento que disminuye conforme avanza la maniobra y se vuelve prácticamente nulo al aproximarse al punto final de estacionamiento. La Fig. 5 presenta la trayectoria resultante en el plano XY, donde se aprecia la curva en S característica de la maniobra de estacionamiento en reversa con dirección Ackermann.




Fig.4 Grafica de comparativa de posición real vs deseada del robot movil tipo coche a lo largo de la maniobra




Fig.5 Grafica del plano XY de la trayectoria seguida por el robot móvil tipo coche durante la maniobra

V. CONCLUSIONES Y TRABAJO A FUTURO

Se desarrolló e implementó exitosamente el Sistema de Estacionamiento Autónomo S.E.A., integrando de manera coherente tres módulos: control, sistemas inteligentes y

electrónica. Cada módulo fue diseñado, simulado y validado de forma individual antes de su integración en el sistema completo.

El controlador adaptable basado en análisis de Lyapunov demostró estabilidad asintótica y convergencia de parámetros, siendo robusto ante variaciones en los parámetros del motor DC. La MLP alcanzó un accuracy superior al 93% en datos no vistos durante el entrenamiento, con arquitectura compacta adecuada para ejecución en tiempo real en la plataforma Jetson. La PCB personalizada integró eficientemente todos los componentes, con especial atención al acondicionamiento de la fuente de alimentación para garantizar operación confiable del sistema digital en presencia de cargas de potencia.

Como trabajo a futuro se propone: incrementar significativamente el conjunto de datos de entrenamiento de la MLP, ya que las 111 muestras utilizadas son relativamente pocas para garantizar robustez ante condiciones variables de entorno; integrar una unidad de medición inercial con acelerómetro y giroscopo fusionada mediante un Filtro de Kalman Extendido para mejorar la estimación de pose del vehículo sin depender únicamente de la odometría; diseñar maniobras de pre-estacionado personalizadas para distintos tipos de cajón (paralelo, en batería, en ángulo), de modo que la trayectoria de aproximación se adapte a la geometría específica de cada espacio; y reducir la distancia mínima de cajón requerida mediante optimización de la planificación de trayectorias, permitiendo al sistema operar en espacios más ajustados que el 150% del tamaño del robot actualmente validado.

RECONOCIMIENTOS

Los autores agradecen al Dr. José de Jesús Hernández Barragán, asesor principal del proyecto, por su guía técnica y apoyo académico a lo largo del desarrollo del S.E.A. Asimismo, se agradece al Centro Universitario de Ciencias Exactas e Ingenierías (CUCEI, UDG) por las instalaciones y recursos proporcionados para la realización de este proyecto modular.

REFERENCIAS

- [1] Z. Wang y D. Liu, "An Overview of Autonomous Parking Systems: Strategies, Challenges, and Future Directions," *Sensors*, vol. 25, no. 14, p. 4328, 2025.
- [2] S. M. LaValle, "Motion Planning for Nonholonomic Vehicles: An Introduction," *IEEE Robotics & Automation Magazine*, vol. 20, no. 2, pp. 10–25, 2020.
- [3] V. Gupta y P. Divekar, "Autonomous parallel parking system for Ackerman steering four wheelers," en *Proc. 2021 International Conference on Artificial Intelligence and Smart Systems (ICAIS)*, Coimbatore, India, 2021, pp. 1235–1240.
- [4] J. Li, B. Zhang, y G. Xu, "Automatic Parking Trajectory Planning Based on Warm Start Nonlinear Dynamic Optimization," *Applied Sciences*, vol. 14, no. 3, p. 1056, 2024.
- [5] F. Pedregosa et al., "Scikit-learn: Machine Learning in Python," *Journal of Machine Learning Research*, vol. 12, pp. 2825–2830, 2011.
- [6] Espressif Systems, ESP32 Technical Reference Manual, ver. 5.1, 2023. [Online]. Available: https://www.espressif.com/sites/default/files/documentation/esp32_technical_reference_manual_en.pdf